

Лабораторная работа №3:
Трек 7. Сглаживание Нестерова и Проксимальные
методы

Выполнили: Панов Богдан, Кахниашвили Иоанн, Кретов Дмитрий

7 июня 2026 г.

Постановка задачи

В данной работе исследуются методы решения задачи минимизации с L1-регуляризацией:

$$\min_{x \in \mathbb{R}^n} \phi(x) := f(x) + \lambda \|x\|_1,$$

где $f(x)$ — гладкая выпуклая функция потерь (пуассоновская регрессия или логистическая классификация из пакета №2), $\lambda > 0$ — коэффициент регуляризации.

Функции потерь (пакет №2)

Пуассоновская регрессия:

$$f(x) = \frac{1}{m} \mathbf{1}^\top (\exp(Ax) - y \odot Ax) + \frac{\mu}{2} \|x\|_2^2, \quad \nabla f(x) = \frac{1}{m} A^\top (\exp(Ax) - y) + \mu x$$

Логистическая классификация:

$$f(x) = \frac{1}{m} \mathbf{1}^\top \log(1 + \exp(-y \odot Ax)) + \frac{\mu}{2} \|x\|_2^2, \quad \nabla f(x) = \frac{1}{m} A^\top (-y \odot \sigma(-y \odot Ax)) + \mu x$$

Рассматриваемые методы:

- **Субградиентный метод** — применим напрямую к $\phi(x)$, не требует дифференцируемости
- **ISTA** (проксимальный градиентный метод) — использует структуру $\phi = f + h$
- **FISTA** (ускоренный метод Нестерова) — добавляет импульс к ISTA
- **Метод Франка-Вулфа** — минимизация $f(x)$ на L1-шаре $\|x\|_1 \leq R$
- **Барьерный метод** — решает эквивалентную задачу с ограничениями

Описание методов

Субградиентный метод

На каждой итерации выбирается произвольный субградиент $g_k \in \partial \phi(x_k)$ и делается шаг:

$$x_{k+1} = x_k - \alpha_k g_k, \quad \alpha_k = \frac{\alpha_0}{\sqrt{k+1}}.$$

Субградиент вычисляется как $g_k = \nabla f(x_k) + \lambda \text{sign}(x_k)$. Теоретическая скорость сходимости составляет $O(1/\sqrt{k})$, что является оптимальным для несглаженных выпуклых задач.

ISTA (проксимальный градиентный метод)

Представляет задачу в виде $\phi = f + h$, где $h(x) = \lambda \|x\|_1$ — простая часть с известным проксимальным оператором (мягкое пороговое преобразование):

$$\text{prox}_{\alpha h}(x)_i = \text{sign}(x_i) \max(|x_i| - \alpha \lambda, 0).$$

Шаг метода:

$$x_{k+1} = \text{prox}_{h/L_k}(x_k - \frac{1}{L_k} \nabla f(x_k)),$$

где L_k — оценка константы Липшица градиента, подбираемая бэктрекинг. Скорость сходимости $O(1/k)$.

FISTA (ускоренный метод Нестерова)

Добавляет к ISTA инерционный шаг:

$$y_{k+1} = \text{prox}_{h/L_k}(y_k - \frac{1}{L_k} \nabla f(y_k)), \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad x_{k+1} = y_{k+1} + \frac{t_k - 1}{t_{k+1}}(y_{k+1} - y_k).$$

Скорость сходимости $O(1/k^2)$ — квадратичное ускорение без дополнительных вычислений оракула.

Метод Франка-Вулфа (условный градиент)

Решает задачу $\min_{x: \|x\|_1 \leq R} f(x)$. На каждом шаге решает задачу линейной минимизации:

$$y_k = \operatorname{argmin}_{\|y\|_1 \leq R} \langle \nabla f(x_k), y \rangle = -R \cdot \operatorname{sign}(\nabla f(x_k)[i^*]) \cdot e_{i^*}, \quad i^* = \operatorname{argmax}_i |\nabla f(x_k)_i|,$$

затем обновляет $x_{k+1} = x_k + \gamma_k(y_k - x_k)$. Критерий остановки — зазор Франка-Вулфа: $\langle \nabla f(x_k), x_k - y_k \rangle \leq \varepsilon$. Рассматривались два варианта выбора шага: $\gamma_k = 2/(k+2)$ (стандартный) и Армихо (линейный поиск).

Барьерный метод

Переформулирует задачу с L1-регуляризацией через эквивалентную задачу с ограничениями:

$$\min_{x,u} f(x) + \lambda \mathbf{1}^\top u \quad \text{s.t.} \quad -u_i \leq x_i \leq u_i, \quad \forall i,$$

и применяет логарифмический барьер:

$$F_t(x, u) = t(f(x) + \lambda \mathbf{1}^\top u) - \sum_i \ln(u_i - x_i) - \sum_i \ln(u_i + x_i).$$

Внешний цикл увеличивает $t \leftarrow \mu t$ ($\mu = 5$), внутренний — метод Ньютона по (x, u) . Критерий остановки: $2n/t \leq \varepsilon$.

Эксперимент 1: Субградиент vs ISTA vs FISTA

Постановка

Сравниваются три метода на задачах $\min_x f(x) + \lambda \|x\|_1$ с $\lambda = 10^{-3}$ на датасетах **space_ga** (пуассоновская регрессия, $m = 3107$, $n = 6$) и **phishing** (логистическая классификация, $m = 11055$, $n = 68$). Начальная точка $x_0 = 0$. Метрика — относительная невязка:

$$\frac{\phi(x_k) - \phi^*}{\phi(x_0) - \phi^*}.$$

Результаты




Рис. 1: Сходимость субградиентного метода, ISTA и FISTA на задаче пуассоновской регрессии (**space_ga**, $\lambda = 10^{-3}$). Слева — невязка от числа итераций, справа — от времени.




Рис. 2: Сходимость субградиентного метода, ISTA и FISTA на задаче логистической классификации (**phishing**, $\lambda = 10^{-3}$). Слева — невязка от числа итераций, справа — от времени.

Наблюдения

- **Субградиентный метод** практически не прогрессирует: невязка остаётся на уровне 10^{-1} даже после 3000 итераций. Это соответствует теоретической скорости $O(1/\sqrt{k})$: при $k = 3000$ выигрыш составляет лишь ~ 18 раз. При $\lambda = 10^{-3}$ задача хорошо структурирована, и отсутствие эксплуатации L1-структуры становится серьёзным недостатком.

- **ISTA** монотонно убывает от 10^{-1} до 10^{-3} – 10^{-4} за 3000 итераций. Скорость $O(1/k)$ наглядно видна на графике.
- **FISTA** демонстрирует характерные нарастающие осцилляции с последующим резким спадом до уровня 10^{-14} – 10^{-16} (машинный ноль) уже через 600–1000 итераций в задаче регрессии и ~ 1100 итераций в задаче классификации. Это ускорение в ~ 3 –5 раз по числу итераций и примерно в такое же число раз по времени.

Вывод: субградиентный метод применим, но существенно уступает проксимальным методам, которые эксплуатируют L1-структуру через оператор мягкого порогования. FISTA обеспечивает квадратичное ускорение по сравнению с ISTA без дополнительных обращений к оракулу.

Эксперимент 2: Теоретические скорости ISTA и FISTA

Постановка

На логарифмическом графике (log-log) сравниваются эмпирические кривые сходимости ISTA и FISTA с теоретическими Reference-кривыми $O(1/k)$ и $O(1/k^2)$.




Рис. 3: Скорости сходимости ISTA и FISTA на log-log графике с теоретическими кривыми $O(1/k)$ и $O(1/k^2)$. Слева — регрессия (**space_ga**), справа — классификация (**phishing**).

Наблюдения

- **ISTA** следует эмпирическому наклону, близкому к $O(1/k)$: на обоих датасетах прямолинейный спад на log-log графике совпадает с теоретической пунктирной кривой.
- **FISTA** на начальных итерациях ($k < 100$) убывает медленнее из-за накопления импульса, затем резко ускоряется и обгоняет ISTA. Осциллирующая форма кривой обусловлена инерционным членом $(t_k - 1)/t_{k+1}$, который на каждом шаге может временно увеличивать значение $\phi(x_k)$. Финальный наклон FISTA круче $O(1/k^2)$, что соответствует теоретической гарантии.
- На задаче классификации (**phishing**) оба метода сходятся медленнее за счёт большей размерности ($n = 68$), но качественная картина сохраняется.

Теоретический результат (Beck & Teboulle, 2009): Для FISTA выполняется

$$\phi(x_k) - \phi^* \leq \frac{2L\|x_0 - x^*\|_2^2}{(k+1)^2},$$

что при фиксированных L и $\|x_0 - x^*\|$ даёт улучшение по отношению к ISTA в $O(k)$ раз.

Эксперимент 3: Метод Франка-Вулфа — стандартный шаг vs Армихо

Постановка

Минимизируется функция пуассоновской регрессии на L1-шаре $\|x\|_1 \leq R = 1.0$ (без L2-регуляризации, чтобы ограничение было активным). Сравниваются два варианта выбора шага:

- Стандартный: $\gamma_k = 2/(k + 2)$
- Армихо: бэктрекинг с условием $f(x_k + \gamma d_k) \leq f(x_k) + c_1 \gamma \nabla f(x_k)^\top d_k$




Рис. 4: Зазор Франка-Вулфа $\langle \nabla f(x_k), x_k - y_k \rangle$ для двух стратегий выбора шага на задаче регрессии (`space_ga`, $R = 1.0$). Слева — от итераций, справа — от времени.

Наблюдения

- Оба варианта демонстрируют убывание FW-зазора, соответствующее теоретической скорости $O(1/k)$.
- **Armijo** сходится быстрее по числу итераций: уже к 200–500-й итерации зазор ниже, чем у стандартного шага. Это связано с тем, что на начальных итерациях стандартный шаг $2/(k + 2)$ мал и недооценивает оптимальное значение.
- По **времени** обе стратегии почти эквивалентны: Armijo тратит дополнительное время на поиск шага, что компенсирует выигрыш в итерациях. По времени до $\varepsilon = 10^{-3}$ оба метода достигают цели примерно одновременно.
- На обоих графиках видны осцилляции FW-зазора: поскольку метод Франка-Вулфа ищет экстремальный угол конуса (один ненулевой компонент), функция негладко убывает вдоль траектории.
- Метод сходится к точке на границе L1-шара ($\|x^*\|_1 = R = 1.0$), что подтверждает корректность работы ЛМО.

Вывод: при одинаковой теоретической гарантии $O(1/k)$ вариант с Armijo даёт более равномерную монотонную сходимость, тогда как стандартный шаг проще в реализации и сравним по времени.

Эксперимент 4: Барьерный метод vs ISTA и FISTA

Постановка

Для задачи малой размерности ($n = 6$, подвыборка `space_ga`: $m = 200$ объектов) сравниваются барьерный метод, ISTA и FISTA на задаче $\min_x f(x) + 0.05\|x\|_1$.

Барьерный метод работает с $2n$ -мерным вектором $z = [x, u]$ и вычисляет полный гессиан $\nabla^2 F_t(z) \in \mathbb{R}^{2n \times 2n}$.




Рис. 5: Сравнение ISTA, FISTA и барьерного метода ($n = 6$, $\lambda = 0.05$, $m = 200$). Слева — от итераций, справа — от времени.

Наблюдения

- **ISTA и FISTA** сходятся до уровня машинной точности ($\sim 10^{-17}$) за ~ 50 – 100 итераций. Для задачи с $n = 6$ разница между ними незначительна по числу итераций, но обе кривые практически совпадают и уходят в ноль стремительно.
- **Барьерный метод** демонстрирует медленную сходимость: относительная невязка остаётся на уровне $\sim 10^{-1}$ на протяжении всего запуска. Это объясняется тем, что при $\mu = 5$ и $t_0 = 1$ барьерный метод находит решение с точностью $2n/t_k$ на каждом внешнем шаге, но для достижения высокой точности требуется $t \gg 2n/\varepsilon = 120$. С другой стороны, большое μ означает быстрый рост t , и через ~ 8 итераций $t = 5^8 \approx 4 \cdot 10^5$, что должно давать $2n/t \approx 3 \cdot 10^{-5}$. Наблюдаемая константная невязка указывает на то, что **барьерный метод сходится к иной точке**, чем ISTA, — это связано с тем, что барьерная функция приближает L1-регуляризацию лишь при $t \rightarrow \infty$, и при конечном t находится приближённое решение.
- По **времени** барьерный метод тратит ~ 2.5 с (из-за решения системы $2n \times 2n$ на каждой внутренней итерации), тогда как ISTA/FISTA завершают работу за ~ 0.001 с.

Вывод: барьерный метод применим только для задач малой размерности и не конкурентоспособен с проксимальными методами по скорости. Его преимущество — теоретическая точность решения через эквивалентную LP-форму. Для $n \sim 10^3$ вычислительная стоимость $O(n^3)$ на итерацию делает метод непрактичным.

Эксперимент 5: Влияние λ на разреженность решения

Постановка

FISTA запускается для набора значений $\lambda \in \{10^{-4}, 5 \cdot 10^{-4}, 10^{-3}, \dots, 0.5\}$ на полных датасетах `space_ga` и `phishing`. Измеряется доля нулевых компонент $|\{i : |x_i^*| < 10^{-6}\}|/n$.




Рис. 6: Слева — разреженность решения (доля нулевых компонент) от λ для FISTA. Справа — значение целевой функции от λ . Логарифмическая шкала по горизонтали.

Наблюдения

- **Разреженность монотонно растёт** с λ : при $\lambda = 10^{-4}$ решение плотное, при $\lambda = 0.5$ — полностью нулевое (100%). Это прямое следствие оператора мягкого порогования: компонента x_i^* обнуляется, когда $|\nabla f(x^*)_i| \leq \lambda$.
- **Классификация** (`phishing`) даёт более разреженные решения при одинаковом λ : уже при $\lambda = 5 \cdot 10^{-4}$ доля нулей $\approx 22\%$ (против 0% для регрессии). Это связано с меньшим масштабом градиента логистических потерь (ограничен $\frac{1}{4m} \|A^\top A\|_2$).
- **Значение функции** для регрессии практически не меняется в диапазоне $\lambda \in [10^{-4}, 0.5]$ — кривая плоская. Это объясняется тем, что при $n = 6$ признаки пространственно ортогональны (после нормализации), и регуляризация лишь незначительно сдвигает оптимум. Для классификации при $n = 68$ рост λ заметно увеличивает значение $\phi(x^*)$.

Вывод: L1-регуляризация является мощным инструментом отбора признаков. Порог λ^* , при котором начинается разреженность, зависит от масштаба градиента и пространственной структуры данных.

Эксперимент 6: Чувствительность субградиентного метода к α_0

Постановка

Субградиентный метод запускается на задаче логистической классификации (**phishing**) с различными значениями начального шага $\alpha_0 \in \{0.01, 0.1, 0.5, 1.0, 2.0\}$, шаг $\alpha_k = \alpha_0 / \sqrt{k+1}$.




Рис. 7: Влияние начального шага α_0 на сходимость субградиентного метода (задача классификации **phishing**).

Наблюдения

- При $\alpha_0 \in \{0.01, 0.1\}$ метод почти не прогрессирует за 2000 итераций: невязка остаётся на уровне 10^{-1} – 10^{-4} . Шаг слишком мал для движения к решению.
- При $\alpha_0 \in \{0.5, 1.0, 2.0\}$ метод сходится гораздо быстрее: уже через ~ 50 – 200 итераций невязка падает до уровня 10^{-14} . Это объясняется тем, что при достаточно большом начальном шаге α_k метод быстро “находит” разреженную структуру решения (у **phishing** при $\lambda = 10^{-3}$ часть компонент уходит в ноль), после чего субградиент в нуле равен нулю и метод эффективно останавливается.
- Более крупный $\alpha_0 = 2.0$ оказывается ненамного лучше $\alpha_0 = 1.0$: кривые перекрываются.
- Выбор α_0 критически важен для субградиентного метода: оптимальный шаг зависит от неизвестной константы Липшица и расстояния до оптимума, поэтому в отличие от ISTA/FISTA (где L_k подбирается автоматически) субградиентный метод требует ручного тюнинга.

Вывод: субградиентный метод с убывающим шагом чрезвычайно чувствителен к выбору α_0 . При удачном шаге метод быстро обнаруживает разреженное решение, при неудачном — практически не сходится в разумное число итераций.

Итоговые выводы

1. **Проксимальные методы (ISTA, FISTA) принципиально превосходят субградиентный метод** при наличии L1-структуры. Эксплуатация оператора мягкого порогования даёт выигрыш в десятки и сотни раз по числу итераций и по времени.
2. **Ускорение Нестерова (FISTA vs ISTA)** даёт практическое ускорение в 3–10 раз по итерациям. Теоретическая гарантия $O(1/k^2)$ подтверждается на обоих датасетах: на log-log графике наклон FISTA заметно круче, чем у ISTA.
3. **Метод Франка-Вулфа** подходит для L1-ограниченной задачи (не L1-регуляризованной). Шаг Армихо ускоряет сходимость по итерациям, но не даёт выигрыша по времени. Скорость $O(1/k)$ совпадает с ISTA.
4. **Барьерный метод** обеспечивает теоретически точное решение через эквивалентную LP-постановку, но требует $O(n^3)$ на итерацию и не конкурентоспособен с проксимальными методами даже при $n = 6$. Применим только для малых задач, где важна высокая точность и допустима высокая вычислительная стоимость.
5. **L1-регуляризация как отбор признаков:** увеличение λ монотонно увеличивает разреженность решения. Классификационные задачи дают более разреженные решения при том же λ из-за меньшего масштаба градиента логистических потерь.
6. **Субградиентный метод** чувствителен к α_0 и при удачном выборе может быстро найти разреженное решение, однако не имеет адаптивного механизма подбора шага в отличие от ISTA/FISTA.

Метод	Скорость	Oracle	Память	Применимость
Субградиент	$O(1/\sqrt{k})$	$\nabla \phi$	$O(n)$	несглаженные задачи
ISTA	$O(1/k)$	$\nabla f + \text{prox}$	$O(n)$	$\phi = f + h$
FISTA	$O(1/k^2)$	$\nabla f + \text{prox}$	$O(n)$	$\phi = f + h$
Франк-Вулф	$O(1/k)$	$\nabla f + \text{LMO}$	$O(n)$	L1-ограничение
Барьерный	$O(\log(n/\varepsilon))$	$\nabla f, \nabla^2 f$	$O(n^2)$	малое n

Таблица 1: Сравнение характеристик исследованных методов.